

Propagación de Información en una red Social

ALEX SÁNCHEZ SAEZ, Universidad de la Habana, Cuba

CARLOS MANUEL GONZÁLEZ, Universidad de la Habana, Cuba

JORGE ALBERTO ASPIOLEA, Universidad de la Habana, Cuba

Este es el resumen Técnico de nuestro proyecto de IA-Simulación para el Curso 2024 , En este proyecto nos propusimos responder a las siguientes interrogantes; ¿Como se difunde la Información en una Red Social? y ¿Sabiendo esto podremos crear una Publicación que se adecúe a nuestras necesidades y que tenga el Mayor crecimiento Posible? . Para responder a esto Creamos una herramienta basándonos en los conocimientos adquiridos en las asignaturas de IA y Simulación y datos recopilados a través de la Investigación y revisión de la bibliografía disponible

Additional Key Words and Phrases: Simulación, Inteligencia Artificial, Red Social

ACM Reference Format:

Alex Sánchez Saez, Carlos Manuel González, and Jorge Alberto Aspiolea. 2024. Propagación de Información en una red Social. 1, 1 (April 2024), 5 pages. <https://doi.org/10.1145/nnnnnnn.nnnnnnn>

1 INTRODUCCIÓN

Este es el Resumen Técnico de nuestro proyecto de IA-Simulación para el Curso 2024. En este proyecto nos propusimos responder a las siguientes interrogantes: ¿Cómo se difunde la Información en una Red Social? y ¿Sabiendo esto, podremos crear una Publicación que se adecúe a nuestras necesidades y que tenga el Mayor Crecimiento Posible? Para abordar estas cuestiones, creamos una herramienta basada en una interfaz en lenguaje natural para interactuar con el usuario, además de una simulación multiagente con arquitectura BDI. Este enfoque nos permitió aprovechar los conocimientos adquiridos en las asignaturas de IA y Simulación, así como los datos recopilados a través de la investigación y revisión de la bibliografía disponible.

2 ACERCA DE LA DIFUSIÓN DE LA INFORMACIÓN EN REDES SOCIALES

Como Parte de nuestra investigación para la creación de este proyecto , nos dimos a la tarea de encontrar y comprender el estado del arte en la representación y análisis computacional de los sistemas sociales complejos como las Redes sociales. Estudiamos El panorama Histórico de la Modelación de este tipo de problemas y Su relación con el Modelo SIR para la propagación de epidemias <https://theconversation.com/covid-19-y-difusion-de-innovaciones-parecidos-razonables-157385>.

Authors' Contact Information: Alex Sánchez Saez, Universidad de la Habana, La Habana, Cuba; Carlos Manuel González, Universidad de la Habana, La Habana, Cuba; Jorge Alberto Aspiolea, Universidad de la Habana, La Habana, Cuba.

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.

© 2024 Copyright held by the owner/author(s). Publication rights licensed to ACM.

ACM XXXX-XXXX/2024/4-ART

<https://doi.org/10.1145/nnnnnnn.nnnnnnn>

Dimos con el Modelo de Difusión de opiniones de Rogers el cuál explica la dinámica de las opiniones a una macro escala , sin tener en cuenta los eventos locales <https://www.eurekando.org/ciencias-sociales/teoria-de-la-difusion-de-rogers-innovacion-y-difusion/>. Analizamos también algunos Modelos Clásicos utilizados para analizar este tipo de problemas. Los problemas Binarios eran simulaciones multiagente donde los agentes tenían solo dos posibles opiniones respecto a un tema -1 o 1 . La forma en que se difundían estas opiniones era variada en dependencia del autor , algunos ejemplos son : Propagación de opiniones por vecinos cercanos (Modelo de Voter) , Opinión Mayoritaria del grupo al que pertenece el agente (Modelo de Majority Rule) , Propagación por los Vecinos con la misma Opinión (Modelo Szrajd) . Una evolución a estos modelos son los modelos Continuos o Modelos Socio-Físicos en los cuales ya los agentes tienen opiniones no binarias , osea un grado de seguridad respecto a su postura con el tema . Algunas formas de propagación de opiniones en estos modelos son : A través de un confidence level o nivel de confianza , esto significa que cuando dos agentes interactúan varían sus opiniones según su nivel de confianza hacia esta (Deffort y Hegselmann-Krausse).

2.1 Nuestro Modelo de Simulación

Nuestra simulación es un sistema multiagente que usa la arquitectura BDI para modelar el comportamiento de un usuario humano dentro de la red .El medio donde se colocan los agentes es una red donde cada agente tiene un nivel de confianza con el resto de agentes , esto es un valor $[-1,1]$ donde 0 significa que el agente (visto como un nodo) está completamente desconectado y el resto indica que tan bien o mal le cae el otro agente . Las interacciones posibles que tienen los agentes son : dar like a la publicacion i , dar dislike a la publicacion i , compartir la publicacion i , con el agente j

2.2 Representación de los datos

Nuestro sistema desde el punto de vista de los modelos Socio-Físicos es un modelo multitema tipo CODA (Continuous Opinions , Discrete Actions) esto debido a que manejamos las opiniones como un parametro privado de los agentes individuales , y estos solo tienen un rango discreto de acciones a realizar .Representamos las Publicaciones al igual que las opiniones como arreglos de numeros , en el caso de las publicaciones numeros entre 0 y 1 que representan que tan relevante es el tema en la publicacion ; y en el caso de las opiniones de los agentes serían numeros entre -1 y 1 que representan que tan de acuerdo esta el agente con el tema en cuestión

3 AGENTES

Cada agente tiene 7 parámetros que definen su comportamiento , estos son sus valores de afinidad que es su opinion respecto a los temas presentes en la red se representa con un array de numero

con valores que están en $[-1,1]$. Trust Affinity que es el valor de confianza que tiene respecto al resto de agentes de la red, se representa como un diccionario de pares (id del agente, valor de confianza), donde el valor de confianza es un número $[-1,1]$. Like, Dislike y Share thresholds, son los umbrales para determinar si el agente realizará alguna de esas acciones. Others impact, Extroversion y Group Conformity, estos representan la componente social del agente con estos parámetros se definirá como asimila la información que obtiene del resto de los agentes. Reaction threshold y Curiosity, representan la curiosidad y la pereza de los agentes, definen cuando el agente reacciona o no a una publicación que llega o a una publicación de alguien que no conoce. Friends definition, affinity threshold y relevance threshold le ayudan al agente a tomar decisiones, con Friends definition determina que usuarios consideras miembro de su grupo o subred y con los otros dos define la forma en que valora un post (en base a su afinidad personal o la relevancia colectiva)

4 ACCIONES QUE EJECUTAN LOS AGENTES Y CÓMO LO HACEN

En cada Step de la simulación los agentes tendrán en sus intenciones las acciones que quieren realizar y por cada una de ellas, las ganas que tienen de realizarlas, se toman entonces las N primeras acciones a realizar por el agente, donde N es un número aleatorio y se mandan a realizar, las acciones posibles a realizar por parte de los agentes son: Dar like a una publicación, dar dislike a una publicación, compartir la publicación i con el agente j . Al reaccionar a una publicación los agentes calculan cuán alineadas están las características de dicha publicación con sus gustos, y la relevancia que tiene esa publicación para su grupo, esto lo hace revisando cuantos de los usuarios que pertenecen a su grupo (con los que tenga más confianza que su Friend definition) y viendo cuáles de estos han dado like a la publicación, tomando esto en cuenta calcula el nivel de gusto que tiene hacia el post en cuestión, luego verifica cuántas de las publicaciones que recuerda son muy similares a esta; Para simular la memoria de un agente guardamos solo las publicaciones que más les hayan impactado, ya sea positiva o negativamente ya que simular a esto funciona la memoria humana, aunque tomando muchas simplificaciones; Si la publicación es algo que el agente ha visto mucho, se penaliza el nivel de gusto, o nivel de relevancia de la publicación al agente. Si la publicación le fue enviada por otro usuario actualiza su relación con él, para esto se tiene en cuenta cuánto le gustó la publicación enviada y las experiencias pasadas con el agente (tanto positiva como negativas, ambos tipos de interacciones pasadas afectan de manera diferente). De igual manera en haciendo uso de la componente de extroversión del agente se toma la decisión de compartir la publicación con el resto de agentes de la red. Teniendo en cuenta el impacto que tienen los demás al agente y cuál es su nivel de conformidad grupal, se ajustan sus afinidades a la publicación vista. Una vez pasado todo este proceso se decide si dar like o dislike a la publicación. Todo esto solo puede pasar si el agente tiene ganas de reaccionar a la publicación, esto se calcula teniendo en cuenta la curiosidad y la pereza del agente

5 GENERACIÓN DE LOS DATOS INICIALES PARA LA SIMULACIÓN

Todos los datos que se utilizan se generan de manera aleatoria utilizando distribuciones normales que se ajustan más al comportamiento de los parámetros en una población. Variando la media y la desviación estándar de dichas distribuciones ajustamos la generación de los parámetros a lo que pide el usuario y al análisis que se hace después

6 ANÁLISIS DE RESULTADOS

Una vez se han hecho las simulaciones tomamos varios datos, en primer lugar vemos la relación de las métricas por publicación (likes, dislikes y veces compartida) para tener una idea de que publicaciones han triunfado más en la red. Según cuáles sean las características que se quieran analizar se toman los posts en donde estas características tengan grado de pertenencia mayor a 0.6 y calculamos sus índices de crecimiento (promedio de sus likes, dislikes y veces compartido) para poder analizar el crecimiento de estos temas en la red. También analizamos las opiniones de los usuarios respecto a los temas dispuestos para analizar; esto nos sirve para determinar que post tiene mejor rendimiento en la red según las necesidades del usuario

7 CRITERIOS DE PARADA

Cada Simulación Individual se detiene cuando los usuarios dejan de interactuar con los posts de la red. Los Datos Obtenidos por la simulación van a depender de como se generan las variables que se usan, por lo que es poco probable que converjan de alguna manera, es por esto que como criterio de parada se le deja a elección del usuario que cantidad de simulaciones se pueden correr en dependencia de su hardware y recursos

8 PROCESAMIENTO DEL LENGUAJE NATURAL (NLP)

El flujo de simulación empieza por pedirle al usuario algunos datos relacionados al estado de la red social que él desea simular y que objetivos tiene con la simulación. Dichos datos están conformados la cantidad de personas en la red social, una **descripción** de la red social a simular, de donde se extraerán los temas más relevantes que se mencionan comúnmente y los objetivos que tiene el usuario con la simulación.

Para esto se usará el procesamiento del lenguaje natural, en donde el usuario introducirá un texto mencionando cuantos usuarios tendrá la red, una breve descripción de los temas que se tratan en la misma y una explicación de sus objetivos con la simulación.

Luego de tener el texto usaremos uno **Large Language Model (LLM)** para extraer la información necesaria del input del usuario. Para realizar una extracción más detallada, se realizaron 3 consultas al LLM:

- Una primera consulta en donde simplemente el LLM extrae la cantidad de personas que habrán en la red social.
- Una segunda consulta en donde el LLM analiza el texto y extrae los temas más relevantes que se ven en la red social y que le asigne a cada tema un número indicando el porcentaje de personas que les interesa comúnmente ese tema.

- Y una tercera consulta en donde el LLM analiza el texto y extrae, basado en los objetivos que expresa el usuario, tres números que representan qué tan importante son los **likes**, **dislikes** y **shares** en la simulación para lograr los objetivos del usuario.

Para obtener correctamente los datos del texto del usuario se exigió que el *prompt* tenga al menos 100 palabras para que sea lo suficientemente expresivo, además de usar algunas técnicas de **Prompt Engineering** como darle un rol al modelo, especificarle un formato específico para la salida y realizar consultas con tareas simples y directas.

8.1 Importancia de los temas en la red

Una vez se extraen los datos usando el LLM, tocaría llevar los temas proporcionados por el modelo al conjunto de temas que tenemos preestablecidos. Para esto vamos usar la representación en **embeddings** de cada tema (incluido los proporcionados por el LLM), así podemos hacer una comparación semántica de cómo de relacionados están dos temas usando la *distancia coseno*.

Supongamos que tenemos n temas preestablecidos en nuestra red social, nuestro objetivo es construir un vector v de n elementos donde $v_i \in [0, 1]$ representa que tan relevante es el tema i en la red social. Sea m la cantidad de temas devueltos por el LLM y p_i la importancia dada a cada una en la red. Si tenemos los embeddings de cada grupo de temas (sean a y b respectivamente), entonces la para calcular la relevancia v_i del tema i en la red social basado en los m temas principales devueltos por el LLM podemos calcularlo como:

$$v_i = \frac{\sum_{j=1}^m p_j \text{sim}(a_i, b_j)}{n}, \forall 1 \leq i \leq n$$

donde $\text{sim}(a_i, b_j)$ es la similitud entre los temas i y j usando los embeddings de cada uno.

Esta suma ponderada de la similitud de los temas devuelto por el LLM multiplicados por la importancia que tiene cada una en la red social, nos da una medida aproximada de la relevancia del tema i en la red social.

8.2 Representación del conocimiento

Con los embeddings calculados, podemos crear una base de conocimiento sobre los temas de la red, que nos ayude a razonar sobre la relación que existe entre los diferentes temas que existen en esta. Para esto calculamos una matriz de correlación que nos dice que tan relacionado está un tema con el resto. Esto lo utilizamos para ajustar los parámetros en la generación de los posts de manera que sea coherente y se ajuste a la petición del usuario de nuestro sistema, digamos que el usuario quiera que la mayoría de sus posts hablen mucho de tecnología, eso implicaría que tecnología debe tener una media más alta que el resto de temas, a su vez, temas que guarden cierta relación con la tecnología deben tener medias semejantes y otros temas muy bajas, porque no tendrán relación con lo que se maneja en la red, esto nos sirve para que la forma de las publicaciones al ser generadas tengan mas coherencia y sean más realistas

9 OPTIMIZACIÓN

Una vez la simulación arroja las estadísticas antes mencionadas, ahora tenemos la interrogante de encontrar *¿qué combinación de temas y en qué cantidad proporciona un mejor alcance en la red?*. Esta interrogante tiene a dos pasos importantes; primero es *¿cómo calificas que una publicación proporciona mayor alcance?* ¿bajo que criterio es interesante realizar una búsqueda de la mejor solución? y en segundo lugar tenemos el problema de *¿Cómo vamos a encontrar dicha solución óptima?*

9.1 Criterios de optimalidad

Para responder la primera pregunta, podemos ver que cada post en la red social se mide por tres estadísticas principales: *cantidad de likes*, *cantidad de dislikes* y *veces compartida*, además que la simulación nos proporciona esas mismas estadísticas enfocándonos esta vez en el tipo de tema, por tanto tendríamos un índice de que tanto gusta cada tema entre los usuarios (cantidad de likes promedio), o cual es el tema que menos gustó (cantidad de dislikes promedio), o incluso cuáles son los temas que más se difundieron, ya sea por gustos o disgustos, en la red (cantidad de veces compartida). Entonces depende de los intereses del tengamos podemos decidir que importancia darle a cada una de esas tres estadísticas.

Para esto lo más interesantes es que, en vez de tener que definir numéricamente que tanto nos interesa una estadística más que otra, definamos en lenguaje natural cuales son nuestras intenciones respecto al tipo de alcance que queremos obtener y de ahí, usando un **LLM** extraer los índices numéricos que más relación tenga con nuestra descripción.

9.2 Encontrar la mejor solución

Para la segunda pregunta de *¿cómo encontrar la mejor solución?*, debemos fijarnos que la solución consiste en un vector x de tamaño n , donde cada componente del vector es un número $x_i \in [0, 1]$ que indica que el tema i debe tener una relevancia x_i en el post para que tenga el mayor alcance.

Para saber si una solución es mejor que otra debemos tener una forma de cuantificar dicha mejora y así poder hacer la comparación. Para esto definimos una función $f : D \rightarrow \mathbb{R}$, donde D es el dominio de todas las soluciones posibles del problema, o sea, todas las formas posibles en las que se puede construir un post, y $f(x) \in \mathbb{R}$ un número que indica que tan buena es la solución. Podemos ver que D es de tamaño infinito, ya que una solución consiste en una distribución de n números entre 0 y 1, y como ese conjunto es no enumerable entonces hay infinitas combinaciones de n números que pertenezcan al rango $[0, 1]$.

Por ende, una buena forma de enfrentar el problema es usando metaheurísticas para encontrar a la función objetivo f un óptimo que se aproxime a la solución real. Como metaheurística usamos **Particles Swarm Optimization (PSO)**, que nos permite tener un enfoque multiagente para explorar el espacio de las soluciones y una implementación sencilla

10 TABLAS DE RESULTADOS EXPERIMENTALES

